

LAPORAN TUGAS 6

Klasifikasi Minat Membeli Produk Secara Online

Menggunakan Naive Bayes Classifier

Mochammad Lintar Arya Dwiputra

NIM: 2024081032

Program Studi: Sistem Informasi

Universitas Pembangunan Jaya

1. Pendahuluan

Laporan ini mendokumentasikan implementasi algoritma Naive Bayes Classifier untuk memprediksi minat pembelian produk secara online. Sistem klasifikasi dibangun berdasarkan tiga atribut utama yang mempengaruhi keputusan pembelian konsumen.

1.1 Tujuan

- Mengimplementasikan algoritma Naive Bayes secara manual dan menggunakan library scikit-learn.
- Menghitung Prior Probability dan Likelihood untuk setiap fitur.
- Menerapkan Laplace Smoothing untuk menghindari probabilitas nol.
- Mengevaluasi performa model pada data training.

1.2 Atribut Data

- **Harga:** Harga
- Murah, Sedang, Mahal
- **Diskon:** Diskon
- Ada, Tidak Ada
- **Ulasan Hasil:** Ulasan Hasil
- Baik, Buruk

Variabel target (label): Tertarik atau Tidak Tertarik membeli produk.

2. Dataset Training

Dataset terdiri dari 8 sampel data dengan 3 fitur dan 1 label kelas. Berikut adalah tabel dataset yang digunakan dalam pelatihan model:

Harga	Diskon	Ulasan Hasil	Hasil
Murah	Ada	Baik	Tertarik
Murah	Ada	Baik	Tertarik
Sedang	Ada	Baik	Tertarik
Mahal	Tidak Ada	Buruk	Tidak Tertarik
Mahal	Tidak Ada	Buruk	Tidak Tertarik
Sedang	Ada	Baik	Tertarik
Sedang	Tidak Ada	Baik	Tertarik
Mahal	Ada	Buruk	Tidak Tertarik

Distribusi kelas:

- Tertarik: 5 sampel (62.5%)
- Tidak Tertarik: 3 sampel (37.5%)

3. Metodologi — Naive Bayes

Naive Bayes adalah algoritma klasifikasi probabilistik yang didasarkan pada Teorema Bayes dengan asumsi independensi antar fitur (naive assumption). Formula yang digunakan:

$$P(\text{Class} \mid X_1, X_2, X_3) \propto P(X_1 \mid \text{Class}) \times P(X_2 \mid \text{Class}) \times P(X_3 \mid \text{Class}) \times P(\text{Class})$$

3.1 Langkah 1 — Prior Probability

Prior Probability adalah probabilitas setiap kelas dalam dataset sebelum mempertimbangkan fitur apapun.

$$\begin{aligned} P(\text{Tertarik}) &= 5 / 8 = 0.6250 \\ P(\text{Tidak Tertarik}) &= 3 / 8 = 0.3750 \end{aligned}$$

3.2 Langkah 2 — Likelihood dengan Laplace Smoothing

Likelihood adalah probabilitas kondisional setiap nilai fitur diberikan suatu kelas. Laplace Smoothing (+1) diterapkan untuk menghindari probabilitas nol.

$$\text{Formula: } P(X_i = x_j \mid \text{Class}) = (\text{Count}(X_i=x_j \text{ dalam Class}) + 1) / (\text{Count}(\text{Class}) + \text{Jumlah Nilai Unik } X_i)$$

Tabel Likelihood — Fitur Harga:

Harga	P(Harga Tertarik)	Nilai	P(Harga Tidak Tertarik)	Nilai
Murah	$(2+1)/(5+3) = 3/8$	0.3750	$(0+1)/(3+3) = 1/6$	0.1667
Sedang	$(3+1)/(5+3) = 4/8$	0.5000	$(0+1)/(3+3) = 1/6$	0.1667
Mahal	$(0+1)/(5+3) = 1/8$	0.1250	$(3+1)/(3+3) = 4/6$	0.6667

Tabel Likelihood — Fitur Diskon:

Diskon	P(Diskon Tertarik)	Nilai	P(Diskon Tidak Tertarik)	Nilai
Ada	$(4+1)/(5+2) = 5/7$	0.7143	$(1+1)/(3+2) = 2/5$	0.4000
Tidak Ada	$(1+1)/(5+2) = 2/7$	0.2857	$(2+1)/(3+2) = 3/5$	0.6000

Tabel Likelihood — Fitur Ulasan Hasil:

Ulasan Hasil	P(Ulasan Tertarik)	Nilai	P(Ulasan Tidak Tertarik)	Nilai
Baik	$(5+1)/(5+2) = 6/7$	0.8571	$(0+1)/(3+2) = 1/5$	0.2000
Buruk	$(0+1)/(5+2) = 1/7$	0.1429	$(3+1)/(3+2) = 4/5$	0.8000

4. Implementasi dengan Scikit-Learn

Selain perhitungan manual, model juga diimplementasikan menggunakan CategoricalNB dari library scikit-learn dengan parameter $\alpha=1.0$ (Laplace Smoothing).

4.1 Preprocessing

Fitur kategorikal dikonversi ke bentuk numerik menggunakan LabelEncoder sebelum dimasukkan ke model:

```
from sklearn.naive_bayes import CategoricalNB
from sklearn.preprocessing import LabelEncoder

model = CategoricalNB(alpha=1.0)
model.fit(X_encoded, y_encoded)
```

Target classes yang dikenali model: ['Tertarik', 'Tidak Tertarik']

4.2 Hasil Prediksi pada Data Training

Berikut adalah hasil prediksi model terhadap data training beserta perbandingan dengan nilai aktual:

Harga	Diskon	Ulasan Hasil	Aktual	Prediksi	✓
Murah	Ada	Baik	Tertarik	Tertarik	✓
Murah	Ada	Baik	Tertarik	Tertarik	✓
Sedang	Ada	Baik	Tertarik	Tertarik	✓
Mahal	Tidak Ada	Buruk	Tidak Tertarik	Tidak Tertarik	✓
Mahal	Tidak Ada	Buruk	Tidak Tertarik	Tidak Tertarik	✓
Sedang	Ada	Baik	Tertarik	Tertarik	✓
Sedang	Tidak Ada	Baik	Tertarik	Tertarik	✓
Mahal	Ada	Buruk	Tidak Tertarik	Tidak Tertarik	✓

Akurasi Model: 100.00% (8/8 prediksi benar)

5. Contoh Perhitungan Posterior

Sebagai ilustrasi, berikut adalah perhitungan posterior untuk kasus uji: Harga=Murah, Diskon=Ada, Ulasan=Baik.

Komponen	Tertarik	Tidak Tertarik
Prior P(Class)	0.6250	0.3750
P(Harga=Murah Class)	0.3750	0.1667
P(Diskon=Ada Class)	0.7143	0.4000
P(Ulasan=Baik Class)	0.8571	0.2000
P(data Class) x P(Class)	0.143495	0.005000
Posterior (normalisasi)	0.9663	0.0337
PREDIKSI	TERTARIK	

Karena $P(\text{Tertarik}|\text{data}) = 0.9663 \gg P(\text{Tidak Tertarik}|\text{data}) = 0.0337$, maka prediksi adalah TERTARIK dengan tingkat keyakinan 96.63%.

6. Interpretasi Hasil

6.1 Penjelasan Komponen Naive Bayes

1. **Prior Probability** — Proporsi setiap kelas dalam data training. Mayoritas data (62.5%) berlabel Tertarik.
2. **Likelihood** — Probabilitas kondisional setiap nilai fitur terhadap kelas. Menggambarkan seberapa kuat setiap fitur menjadi indikator kelas tertentu.
3. **Laplace Smoothing** — Diterapkan dengan menambahkan +1 pada pembilang dan +k (jumlah nilai unik) pada penyebut untuk menghindari probabilitas nol.
4. **Naive Assumption** — Semua fitur dianggap independen satu sama lain. Meski jarang terjadi di dunia nyata, asumsi ini membuat komputasi sederhana dan tetap efektif.
5. **Posterior Probability** — Hasil akhir klasifikasi berdasarkan Teorema Bayes. Kelas dengan nilai posterior tertinggi dijadikan prediksi akhir.

6.2 Pengaruh Setiap Fitur

- Harga Murah/Sedang → probabilitas Tertarik tinggi (0.3750 / 0.5000 vs 0.1667)
- Harga Mahal → probabilitas Tidak Tertarik jauh lebih tinggi (0.6667 vs 0.1250)
- Diskon Ada → meningkatkan probabilitas Tertarik secara signifikan (0.7143 vs 0.4000)
- Ulasan Baik → faktor paling kuat untuk Tertarik (0.8571 vs 0.2000)
- Ulasan Buruk → faktor paling kuat untuk Tidak Tertarik (0.8000 vs 0.1429)

7. Kesimpulan

Model Naive Bayes berhasil diimplementasikan dengan hasil yang sangat baik:

- Akurasi mencapai 100% pada data training (8/8 prediksi benar).
- Fitur Ulasan Hasil adalah fitur dengan diskriminasi kelas paling kuat.
- Laplace Smoothing berhasil menangani kasus kombinasi fitur yang tidak ada di data training.
- Model dapat digunakan untuk memprediksi minat pembelian pelanggan baru berdasarkan tiga atribut tersebut.

Keterbatasan: Dataset yang kecil (8 sampel) membuat hasil akurasi 100% wajar, namun belum cukup representatif untuk generalisasi ke data yang lebih besar. Pengujian dengan data test yang terpisah diperlukan untuk validasi yang lebih objektif.