

TUGAS 7

Naive Bayes: Evaluasi Model Klasifikasi

Mata Kuliah: Introduction To AI
Survei Penggunaan Platform Belajar Online

Identitas Anggota Kelompok		
Keterangan	Mahasiswa 1	Mahasiswa 2
Nama Lengkap	Mochammad Lintar Arya Dwiputra	Karla Andara Putri
NIM	2024081032	2025011032
Program Studi	Sistem Informasi	Akuntansi

Aktivitas 1: Pemahaman Konsep

1.1 Perbedaan Training Data dan Testing Data

Dalam konteks notebook ini, dataset survei berjumlah 25 responden dibagi menjadi dua bagian menggunakan fungsi `train_test_split` dengan proporsi 80:20. Artinya, sebanyak 20 data digunakan sebagai training data, sedangkan 5 data sisanya digunakan sebagai testing data.

Training data adalah kumpulan data yang digunakan untuk melatih model — dalam hal ini, model Naive Bayes MultinomialNB mempelajari pola hubungan antara fitur (seperti platform yang digunakan, jam belajar, perangkat, dll.) dengan label kepuasan (Rendah, Sedang, Tinggi). Model "belajar" dari data ini untuk membangun probabilitas yang dibutuhkan dalam klasifikasi.

Testing data adalah data yang tidak pernah dilihat oleh model selama proses training. Data ini digunakan untuk menguji seberapa baik model mampu memprediksi label pada data baru yang belum dikenal. Pada notebook, testing data menghasilkan 5 baris data yang digunakan untuk mengukur akurasi akhir model.

Pemisahan ini penting agar evaluasi model bersifat objektif — jika model diuji pada data yang sama dengan data latih, maka hasil evaluasi tidak dapat dipercaya karena model sudah "hafal" data tersebut.

1.2 Mengapa Model Harus Dievaluasi

Model machine learning tidak secara otomatis benar hanya karena sudah dilatih. Evaluasi diperlukan untuk mengetahui apakah model benar-benar mampu menggeneralisasi pola dari data latih ke data baru, atau justru hanya menghafal data latih (overfitting).

Pada notebook ini, evaluasi dilakukan menggunakan tiga metrik utama: `accuracy_score` untuk mengukur persentase prediksi yang benar secara keseluruhan, `classification_report` untuk melihat precision, recall, dan F1-score per kelas, serta `confusion_matrix` untuk melihat distribusi kesalahan prediksi antar kelas.

Tanpa evaluasi, kita tidak memiliki dasar untuk menyatakan apakah model layak digunakan dalam pengambilan keputusan. Evaluasi juga membantu mengidentifikasi kelemahan model — misalnya, dari confusion matrix terlihat bahwa model pada notebook ini gagal mengenali kelas Rendah dan Tinggi, dan hanya berhasil memprediksi kelas Sedang.

1.3 Arti Akurasi 80%

Akurasi 80% berarti bahwa dari seluruh data testing yang diberikan kepada model, sebanyak 80% di antaranya berhasil diprediksi dengan label yang tepat, sedangkan 20% sisanya salah diklasifikasikan.

Sebagai ilustrasi: jika terdapat 10 data testing dan model mendapat akurasi 80%, maka 8 prediksi benar dan 2 salah. Namun perlu dicatat bahwa akurasi 80% tidak selalu bermakna sama di semua konteks — tergantung pada distribusi kelas dan konsekuensi dari kesalahan prediksi.

Perlu dicatat bahwa akurasi aktual model pada notebook ini adalah 60% (3 dari 5 data testing diprediksi benar). Angka 80% dalam soal ini merupakan skenario hipotetis untuk membangun pemahaman konsep evaluasi model.

Aktivitas 2: Analisis Kasus

Berikut adalah skenario hasil prediksi model terhadap 10 data testing yang disimulasikan berdasarkan distribusi kelas yang ada pada notebook (Rendah, Sedang, Tinggi):

No.	Label Aktual	Prediksi Model	Hasil
1	Rendah	Sedang	Salah
2	Sedang	Sedang	Benar
3	Sedang	Tinggi	Salah
4	Sedang	Sedang	Benar
5	Tinggi	Sedang	Salah
6	Sedang	Sedang	Benar
7	Sedang	Sedang	Benar
8	Rendah	Rendah	Benar

9	Sedang	Sedang	Benar
10	Tinggi	Tinggi	Benar

2.1 Jumlah Prediksi Benar

Berdasarkan tabel di atas, prediksi yang benar (label aktual sama dengan prediksi model) adalah pada data nomor 2, 4, 6, 7, 8, 9, dan 10. Total prediksi benar = 7 dari 10 data.

2.2 Perhitungan Akurasi

Rumus akurasi:

$$\text{Akurasi} = (\text{Jumlah Prediksi Benar}) / (\text{Total Data}) \times 100\%$$

$$\text{Akurasi} = 7 / 10 \times 100\% = 70\%$$

2.3 Interpretasi Hasil

Akurasi 70% berarti model berhasil mengklasifikasikan 7 dari 10 data testing dengan benar. Secara umum, angka ini tergolong cukup baik untuk dataset kecil seperti survei ini yang hanya memiliki 25 responden.

Namun perlu diperhatikan bahwa kesalahan terjadi pada kelas Rendah (data 1) dan Tinggi (data 3 dan 5), di mana model cenderung salah mengklasifikasikan keduanya sebagai kelas Sedang. Hal ini konsisten dengan temuan pada notebook, di mana model hanya mampu memprediksi kelas mayoritas (Sedang: 13 dari 25 data) dengan baik, sementara kelas minoritas (Rendah: 5, Tinggi: 7) sulit dikenali karena jumlah sampel training yang sangat terbatas.

Dari skenario ini dapat disimpulkan bahwa meskipun akurasi menunjukkan angka yang tampak memadai, performa model sesungguhnya tidak seimbang antar kelas.

Aktivitas 3: Refleksi

3.1 Apakah Akurasi Saja Cukup untuk Menilai Model?

Menurut kami, akurasi saja tidak cukup untuk menilai kualitas sebuah model klasifikasi, terutama ketika distribusi kelas tidak seimbang (imbalanced classes). Notebook ini menjadi contoh nyata dari keterbatasan tersebut.

Model pada notebook menghasilkan akurasi 60% pada 5 data testing, namun dari classification report terlihat bahwa nilai precision dan recall untuk kelas Rendah dan Tinggi adalah 0.00 — artinya model sama sekali tidak mampu mengenali kedua kelas tersebut. Model hanya memprediksi semua data sebagai kelas Sedang, yang kebetulan merupakan kelas mayoritas dalam dataset (13 dari 25 data). Akurasi 60% diperoleh bukan karena model memahami pola dengan baik, melainkan karena kelas Sedang mendominasi data testing.

Oleh karena itu, metrik seperti precision, recall, F1-score, dan confusion matrix jauh lebih informatif dalam kondisi seperti ini. Macro average F1-score pada notebook hanya 0.25, yang lebih jujur menggambarkan performa model yang sesungguhnya buruk.

3.2 Dalam Kasus Apa Evaluasi Harus Lebih Teliti?

Evaluasi harus dilakukan lebih teliti dan menyeluruh dalam beberapa situasi berikut:

- Distribusi kelas tidak seimbang: Seperti pada notebook ini, di mana kelas Sedang (13 data) jauh lebih banyak dari Rendah (5) dan Tinggi (7). Akurasi tinggi bisa menyesatkan karena model cukup "menebak" kelas mayoritas untuk terlihat akurat.
- Dataset sangat kecil: Dengan hanya 25 data dan test set 5 data, satu kesalahan prediksi langsung mengubah akurasi sebesar 20%. Evaluasi tunggal tidak dapat diandalkan — idealnya digunakan cross-validation.
- Konsekuensi kesalahan berbeda antar kelas: Misalnya dalam klasifikasi medis, salah memprediksi pasien sakit sebagai sehat (false negative) jauh lebih berbahaya daripada sebaliknya. Dalam konteks survei kepuasan, salah mengidentifikasi pengguna yang tidak puas (kelas Rendah) bisa menyebabkan intervensi yang tepat tidak dilakukan.
- Model digunakan untuk pengambilan keputusan nyata: Jika output model akan digunakan untuk kebijakan atau tindakan konkret, maka evaluasi harus mencakup uji robustness, analisis bias, dan validasi lintas dataset.

Kesimpulannya, evaluasi model yang baik harus mempertimbangkan tidak hanya angka akurasi, tetapi juga konteks penggunaan, distribusi data, dan konsekuensi dari kesalahan klasifikasi. Notebook ini adalah pembelajaran yang baik bahwa angka akurasi semata bisa memberikan gambaran yang menyesatkan jika tidak diimbangi dengan analisis metrik yang lebih komprehensif.